

Groupes	Missions	Difficultés	A améliorer	Modification effectuée en cours	Taux de réussite
Site web de la préfecture	Téléchargement : création d'un code permettant de récupérer les RAA	L'écriture du code en python qui permet d'extraire chaque RAA individuellement. Lenteur de téléchargement car le site bloque les téléchargements massifs.	La vitesse de téléchargement.	Réécriture du code à plusieurs reprises	70%
Front	Interface du projet	Aucune difficulté rencontrée.	Plus de communication entre les équipes.	Amélioration de l'expérience utilisateur.	90%
Extraction d'un texte PDF vers un fichier TXT	Prendre le texte du PDF interroger et mettre dans un fichier TXT qu'il n'y a pas d'erreurs de retranscription.	Difficulté rencontrée pour les pdf contenant de l'écriture invisible ou du formatage pour le texte, qui est lu par le code tel quel.	Lien entre tous les systèmes.	Prendre en compte les différentes options (PDF scanné ou texte avec image qui nécessitait une OCR).	100%
OCR	Lecture de PDF et transformation en fichier TXT.	Installation : aller dans tous les chemins d'accès du PC. Faire fonctionner le code : téléchargement d'une bibliothèque	La vitesse ; la qualité de l'OCR. Qui dépend de l'OCR utilisé en lui même. La qualité de retranscription.	Ajout des codes de lecture.	100%

		de langue, choix du type d'OCR.			
Nettoyage et normalisation	Trouver une structure uniforme pour chaque RAA : enlever les espaces. Sortir les RAA en arrêtés. Nettoyer les RAA.	Bug de code : compilation Segmenter les RAA en différents arrêtés.	Plus d'indications de la part du professeur. Les groupes peuvent changer les missions sans communication.	On est passé d'une application web à un outil python directement exécutable depuis la ligne de commande Un code python qui lance directement les dossiers prêts dans l'explorateur Windows. Extraction des arrêtés des RAA en fichier arrêtés rangés par RAA. Ajout de l'en-tête du RAA ainsi que du sommaire dans chaque fichier arrêté correspondant. L'objectif est d'avoir la préfecture et sous-préfecture indiquées Correction encodage + mojibake Normalisation NFC + homoglyphes Réparation erreurs OCR + regexp	100%

				Typographie française Segmenter les RAA avec des titres : le sommaire, les visas etc. Uniformisation de la syntaxe des articles/alinéas Harmonisation capitalisation	
REGEX	Extraire des informations des documents, arrêtés à partir d'expression.	difficultés à identifier quels articles correspondent à quels codes juridiques vu qu'il n'y a pas de manière formalisée d'écrire les visa.	Plus d'explications de la part du professeur. Avec des missions plus claires et précises pour découper le projet par petite étapes	Choix pris de ne pas récupérer la base légale exactement mais de la diviser dans la base de données en 2 catégorie, une réunissant tout les articles et l'autre tous les codes cités dans l'arrêté, cependant cela empêche de savoir qu'elles articles correspondent à quels codes	100%
Base de données	Création de la base de données qui accueille le texte brut du RAA et les métadonnées (fonction de la personne qui a pris la décision,	Faire fonctionner un code SQL. création d'une API pour relier la base de données avec le front (Appeler l'API	Les compétences : trop d'utilisation d'IA. difficulté à faire fonctionner MYSQL workbench	Base de données séparée en plusieurs tables et regroupement de ces bases. Modification de l'affichage	100%

	date, sujet etc...).	PHP depuis le frontend HTML) Dates des arrêtés qui n'étaient pas dans la même forme	difficulté dans la création du code en SQL notamment lors de l'intégration des données	des dates dans la base de données Vérifier supprimer les données de test sur le site internet	
Création d'une base de donné	Extraction manuelle de chaque RAA Code python sur chatgpt : prompt pour obtenir, les données des RAA qui constituent la base de données dans un langage SQL. Audit de la conformité des projets de chacun.	Générer les RAA à la main : long. Demande à l'IA le « bon » prompt et la « bonne » requête.	Plus d'explications de la part du professeur. Comprendre ce que font les autres groupes.	Code python : prompt pour recenser les RAA —> un autre groupe a fait du web scraping. Création des requêtes grâce à l'IA en SQL pour créer les tables.	100%
Analyse du contenu	Identifier et extraire les informations clés de chaque arrêté : objet, signataire, date, visa réglementaire , dispositif. Exploitation des résultats REGEX et du texte normalisé pour	Hétérogénéité de la rédaction des arrêtés selon les préfectures : certains champs absents ou formulés différemment. Difficulté à automatiser complètement l'extraction sans erreurs	Meilleure coordination avec les groupes REGEX et nettoyage. Définir un format de sortie commun dès le début du projet.	Contrôle manuel sur un échantillon d'arrêtés. Révision des expressions régulières selon les cas non couverts.	90%

	alimenter les métadonnées.	résiduelles.			
Classement et structuration	Organiser les arrêtés dans une structure hiérarchique : tri par date, thème, préfecture et type d'acte. Catégorisation pour faciliter la recherche via le front.	Définir une taxonomie adaptée à la diversité des sujets couverts. Absence de catégories standardisées entre préfectures.	Impliquer les groupes front et base de données plus tôt pour aligner la structure avec les besoins d'affichage.	Classement en arborescence par année, département et thème. Ajout de tags pour des recherches transversales.	100%
Stockage final	Consolider les données traitées (texte brut, métadonnées, fichiers arrêtés) dans la base finale. Vérifier l'intégrité avant mise à disposition via le front.	Assurer la cohérence entre les différentes tables issues de groupes distincts. Gestion des doublons et entrées mal formatées.	Mettre en place des tests automatiques de validation à chaque insertion. Documenter les contraintes de la base pour les autres groupes.	Ajout de clés étrangères pour garantir l'intégrité référentielle. Script de vérification global exécuté à la fin du pipeline.	100%